جامعة ابن طفيل
ⵜⴰⵙⴷⴰⵡⵉⵜ ⵉⴱⵏ ⵟⴼⵉⵍ
Ibn Tofaïl University

UNIVERSITÉ IBN TOFAIL

Master Big Data, Intelligence Artificielle & Applications Avancées

RAPPORT DE PROJET

Compression Adaptative de Signaux Physiologiques Multi-Capteurs par Sélection Dynamique d'Algorithme via Métaheuristique

Réalisé par : Bilal Jellaoui, Mohamed Azil, Ayoube Echihami

Encadré par : Pr. Ayoub Sghir

Année universitaire 2025-2026

Table des matières

Résumé **2**

1 Introduction **3**

2 Définitions et fondements conceptuels **5**
2.1 Signaux physiologiques multi-capteurs 5
2.2 Compression de données : concepts fondamentaux 6
2.3 Familles d'algorithmes de compression 6
2.4 Métaheuristiques et algorithmes génétiques 7
2.5 Segmentation et caractérisation locale du signal 8

3 Travaux similaires **9**
3.1 Compression de signaux ECG par transformées et ondelettes 9
3.2 Optimisation de la compression par métaheuristiques 9
3.3 Compression dans les réseaux de capteurs corporels et l'IoT 10
3.4 Approches par apprentissage profond 10
3.5 Positionnement et valeur ajoutée du projet 11

4 Méthodologie **12**
4.1 Choix et validation du dataset 12
4.2 Segmentation des signaux 12
4.3 Caractéristiques extraites par segment 13
4.4 Sélecteur multi-critères 13
4.5 Métaheuristique et fonction objectif 14
4.6 Filet de sécurité post-compression (contribution personnelle) 14

5 Architecture **16**
5.1 Vue d'ensemble du pipeline 16
5.2 Organisation logicielle 16
5.3 Environnement technique 17

6 Discussion et résultats **18**
6.1 Benchmark des six algorithmes à seuils fixes 18
6.2 Défaillance de DCT et DWT sur le canal EMG 20
6.3 Un biais méthodologique identifié et corrigé : ratio moyen versus ratio global 21
6.4 Gain de stockage réel (export Parquet et HDF5) 21
6.5 Généralisation multi-sujets 22
6.6 Validation du filet de sécurité sur l'ensemble des sujets 23
6.7 Impact de la compression sur une tâche d'apprentissage automatique en aval 24
6.8 Effet de la taille du segment sur l'efficacité de compression 25
6.9 Application annexe : détection d'anomalies par erreur de reconstruction 26
6.10 Comparaison avec une méthode métaheuristique existante (Particle Swarm Optimization) 27

7 Conclusion et perspectives **28**

8 Références **30**

Résumé

Les objets connectés de santé (montres connectées, capteurs thoraciques, dispositifs Holter) génèrent en continu des flux physiologiques multi-capteurs — ECG, activité électrodermale (EDA), électromyogramme (EMG), respiration, température, accélération et pouls (BVP) — à des fréquences d'échantillonnage hétérogènes (4 Hz à 700 Hz). Stocker et transmettre ces flux sans compression est coûteux en bande passante, en stockage et en énergie embarquée. Ce projet propose un système de compression adaptative qui, plutôt que d'appliquer un algorithme unique à l'ensemble des signaux, sélectionne dynamiquement — segment par segment — la technique de compression la plus adaptée parmi six algorithmes représentatifs de familles différentes (RLE, LZ77, Huffman adaptatif, Delta/DPCM, DCT, DWT), en fonction de trois critères explicites : la taille relative du segment, sa similarité séquentielle avec le segment précédent, et son entropie de Shannon.

La sélection est pilotée par un sélecteur multi-critères dont les cinq seuils sont optimisés hors-ligne par un algorithme génétique (bibliothèque DEAP), au moyen d'une fonction objectif combinant le taux de compression global, l'erreur de reconstruction (PRD) pondérée par la criticité clinique du capteur, le coût de calcul, et l'équilibre d'utilisation des algorithmes. Une contribution personnelle du projet est l'ajout d'un filet de sécurité post-compression : si la distorsion mesurée dépasse un seuil critique (15 %), le système bascule automatiquement vers un algorithme de repli quasi sans perte — mécanisme qui s'est révélé indispensable face à l'échec catastrophique (PRD $>$ 42 %) des méthodes fréquentielles (DCT, DWT) sur le canal EMG, large bande et peu structuré.

Le système est validé sur le dataset WESAD (13 des 15 sujets disponibles, signaux RespiBAN à 700 Hz et Empatica E4 à 4/32/64 Hz), avec une généralisation testée sur des sujets jamais vus lors de l'apprentissage des seuils. Les résultats montrent un ratio de compression global réel (et non une simple moyenne de ratios par segment, source d'un biais statistique identifié et corrigé au cours du projet) de 2,4 à 2,9× selon les sujets, pour une erreur de reconstruction moyenne inférieure à 0,5 %, avec zéro dépassement du seuil de sécurité clinique sur l'ensemble des sujets testés.

1. Introduction

1.1 Contexte

La multiplication des dispositifs portables de santé (wearables) a transformé la manière dont les signaux physiologiques sont acquis, stockés et transmis. Un dispositif comme l'Empatica E4 ou le RespiBAN Professional enregistre simultanément plusieurs modalités — activité cardiaque (ECG), activité électrodermale (EDA), activité musculaire (EMG), respiration, température cutanée et accélération — chacune avec sa propre fréquence d'échantillonnage et ses propres caractéristiques statistiques. Un signal ECG à 700 Hz produit, par exemple, plus de 60 millions d'échantillons par jour et par capteur, ce qui pose des contraintes fortes de stockage, de bande passante de transmission et, surtout, d'autonomie énergétique pour les dispositifs alimentés par batterie.

La compression de données est la réponse naturelle à ce problème. La littérature et la pratique industrielle appliquent cependant le plus souvent un algorithme de compression unique et fixe à l'ensemble d'un flux de données, indépendamment de sa nature. Nous pensons que cette approche est sous-optimale : un signal ECG, riche en transitoires (complexes QRS), ne se compresse pas de la même manière qu'un signal de température, quasi constant, ou qu'un signal EMG, large bande et proche du bruit. C'est ce constat, assez simple au fond, qui nous a poussés à construire un système qui adapte dynamiquement son choix d'algorithme aux caractéristiques locales du signal, plutôt que d'en imposer un seul à l'ensemble du flux.

1.2 Problématique

Nous formulons donc la problématique centrale de notre projet ainsi : comment sélectionner dynamiquement, pour chaque segment d'un flux physiologique multi-capteurs, l'algorithme de compression le plus adapté, selon des critères explicites (seuil, séquence, taille), tout en garantissant à la fois un gain de stockage réel et une fidélité de reconstruction compatible avec l'usage clinique du signal ?

Avant de nous lancer, nous avons soumis cette problématique à notre encadrant, qui l'a validée et affinée en insistant sur trois exigences méthodologiques : limiter le nombre d'algorithmes comparés à quelques techniques représentatives de familles différentes plutôt qu'une liste exhaustive, définir clairement notre méthodologie de segmentation des signaux et les caractéristiques utilisées pour décrire chaque segment, et définir explicitement la fonction objectif de notre métaheuristique. Ces trois exigences ont structuré l'ensemble de notre travail, et nous les retrouvons à chaque chapitre de ce rapport.

1.3 Objectifs du projet

— Concevoir et implémenter six algorithmes de compression représentatifs de familles différentes (redondance, dictionnaire, entropique, prédictif, transformées fréquentielle et en ondelettes) ;

— Définir une segmentation et un ensemble de caractéristiques par segment permettant de décrire objectivement chaque portion de signal ;
— Construire un sélecteur multi-critères (taille, séquence, seuil d'entropie) capable d'orienter chaque segment vers l'algorithme le plus pertinent ;
— Optimiser les seuils de ce sélecteur par une métaheuristique (algorithme génétique) dont la fonction objectif intègre le taux de compression, la fidélité de reconstruction pondérée cliniquement, le coût de calcul et la diversité d'utilisation des algorithmes ;
— Valider la généralisation du système sur des sujets non vus lors de l'apprentissage des seuils, et évaluer sa robustesse sur une tâche d'apprentissage automatique en aval (classification de l'état de stress) ;
— Comparer notre approche aux solutions fixes existantes et situer notre contribution par rapport aux travaux publiés sur la compression de signaux physiologiques.

1.4 Organisation du rapport

Nous organisons ce rapport comme suit. Le chapitre 2 pose les définitions et fondements conceptuels nécessaires à la compréhension du projet (signaux physiologiques, compression de données, métaheuristiques). Le chapitre 3 situe notre travail par rapport aux travaux similaires et à l'état de l'art 2020-2026. Le chapitre 4 détaille notre méthodologie — dataset, segmentation, caractéristiques, sélecteur, fonction objectif. Le chapitre 5 décrit l'architecture logicielle de notre système. Le chapitre 6 présente et discute nos résultats expérimentaux, y compris deux difficultés méthodologiques que nous avons rencontrées et corrigées en cours de projet. Le chapitre 7 conclut et ouvre des perspectives.

2. Définitions et fondements conceptuels

2.1 Signaux physiologiques multi-capteurs

Un signal physiologique est une grandeur mesurée en continu, reflétant l'activité d'un système biologique. Le dataset utilisé dans ce projet (WESAD, détaillé en section 4.1) combine deux dispositifs :

— Le dispositif thoracique RespiBAN, échantillonné à 700 Hz, qui enregistre l'électrocardiogramme (ECG), l'activité électrodermale (EDA), l'électromyogramme (EMG), la respiration (RESP), la température cutanée (TEMP) et l'accélération 3 axes (ACC) ;
— Le dispositif au poignet Empatica E4, dont les canaux sont échantillonnés à des fréquences hétérogènes (BVP à 64 Hz, ACC à 32 Hz, EDA et TEMP à 4 Hz), qui enregistre le pouls (Blood Volume Pulse), l'activité électrodermale, la température cutanée et l'accélération.

Ces dix canaux ont des propriétés statistiques radicalement différentes. L'ECG est un signal quasi périodique dominé par des transitoires de forte amplitude (le complexe QRS) séparés par des segments plats ; l'EMG est un signal large bande, proche d'un bruit blanc, reflétant l'activité électrique globale des fibres musculaires ; l'EDA et la température varient lentement, avec une forte autocorrélation ; l'accélération capture des mouvements corporels de fréquence variable. Cette hétérogénéité est le fondement même de la problématique du projet : aucun algorithme unique ne peut être optimal simultanément sur ces dix profils de signal.

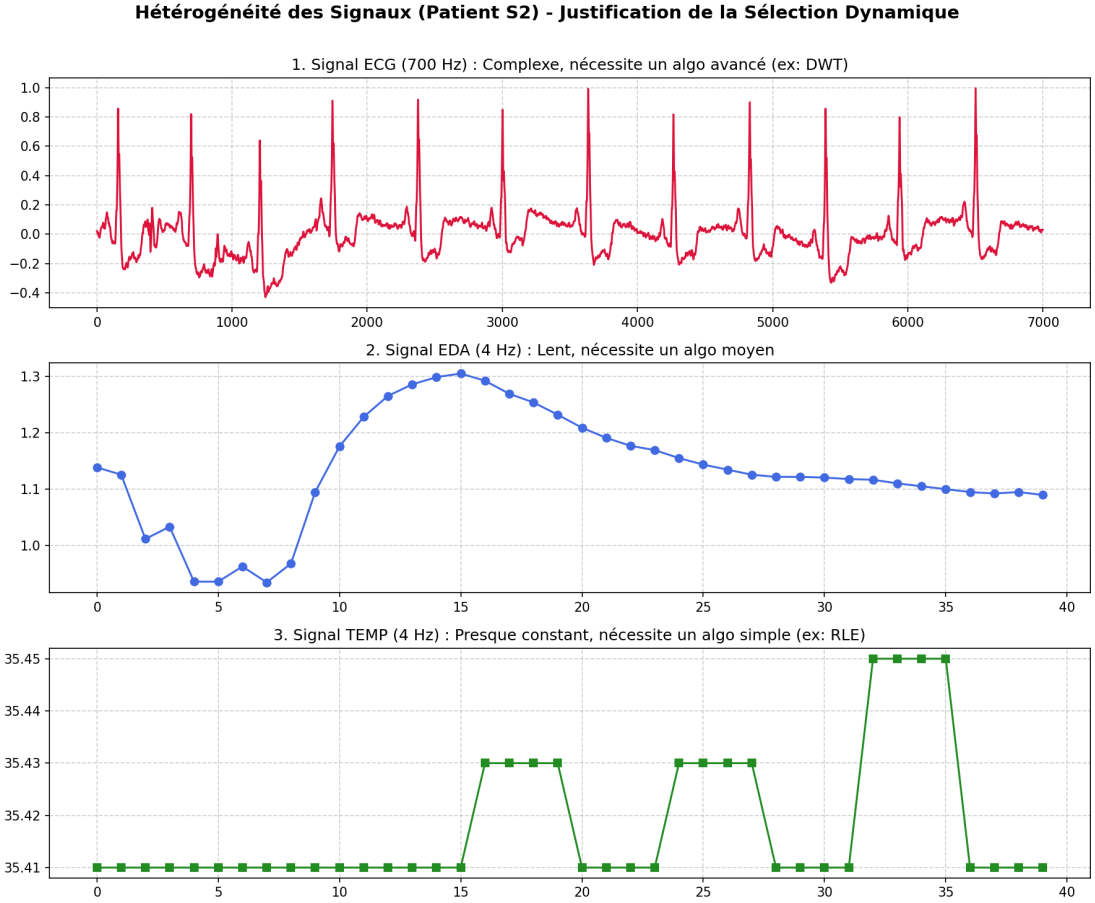


Figure 1 — Trois profils de signal radicalement différents (sujet S2) : ECG (700 Hz, transitoire), EDA (4 Hz, lent), TEMP (4 Hz, quasi constant).

2.2 Compression de données : concepts fondamentaux

2.2.1 Compression avec et sans perte

Un algorithme de compression avec perte (lossy) réduit la taille des données en acceptant une dégradation de l'information d'origine, généralement imperceptible ou tolérable pour l'usage visé. Un algorithme sans perte (lossless) garantit une reconstruction bit-à-bit identique à l'original. Dans ce projet, RLE, LZ77 et Huffman adaptatif sont appliqués sans perte sur une représentation quantifiée du signal, tandis que Delta/DPCM, DCT et DWT introduisent, selon leur paramétrage, une perte contrôlée.

2.2.2 Métriques d'évaluation : CR et PRD

Deux métriques structurent l'ensemble de l'évaluation de ce projet :

— Le taux de compression (Compression Ratio, CR) est le rapport entre la taille du signal original et la taille du signal compressé. Un CR de 3 signifie que la version compressée occupe le tiers de l'espace initial.
— Le Percentage RMS Difference (PRD) mesure la fidélité de reconstruction, exprimée en pourcentage de l'énergie du signal original. Un PRD proche de 0 % indique une reconstruction quasi parfaite ; un PRD supérieur à 10-15 % est généralement considéré comme cliniquement inacceptable pour un signal comme l'ECG, où il peut masquer une anomalie de rythme.

Un point méthodologique important, développé en détail au chapitre 6, est la distinction entre le CR moyen (moyenne arithmétique des ratios obtenus segment par segment) et le CR global (rapport entre la somme des tailles brutes et la somme des tailles compressées sur l'ensemble des segments). Ces deux quantités, souvent confondues dans la littérature étudiante, peuvent diverger fortement lorsque la distribution des ratios par segment est asymétrique.

2.3 Familles d'algorithmes de compression

Sur les dix algorithmes initialement envisagés (RLE, Delta/DPCM, Delta-Delta, Huffman adaptatif, LZW, DCT, DWT, EZW, SPIHT, CS-DCT), six ont été retenus dans la version finale du projet, à la demande explicite de l'encadrant, en veillant à représenter des familles algorithmiques distinctes plutôt qu'une accumulation de variantes proches.

Algorithme	**Famille**	**Principe**
RLE (Run-Length Encoding)	Redondance	Remplace les suites de valeurs identiques par un couple (valeur, longueur de répétition).

LZ77	Dictionnaire (fenêtre glissante)	Remplace les motifs déjà rencontrés par une référence (distance, longueur) vers leur occurrence précédente.
Huffman adaptatif	Codage entropique	Attribue des codes binaires de longueur variable inversement proportionnelle à la fréquence des symboles, recalculés par bloc pour s'adapter à la non-stationnarité du signal.
Delta / DPCM	Prédictif	Code la différence entre échantillons consécutifs plutôt que leur valeur absolue, exploitant la corrélation temporelle du signal.
DCT (transformée en cosinus discrète)	Transformée fréquentielle	Concentre l'énergie du signal sur un petit nombre de coefficients fréquentiels, dont seuls les plus significatifs sont conservés.
DWT (transformée en ondelettes discrète)	Transformée multi-résolution	Décompose le signal en sous-bandes temps-fréquence, permettant un seuillage adapté à chaque échelle.

Tableau 1 — Les six familles d'algorithmes de compression retenues dans le projet.

Chaque famille présente un compromis distinct entre taux de compression, fidélité et coût de calcul. RLE et Delta sont extrêmement rapides mais peu efficaces sur des signaux sans redondance locale forte ; DCT et DWT atteignent des taux de compression élevés au prix d'une perte contrôlée, mais peuvent échouer catastrophiquement sur des signaux ne présentant pas de structure exploitable dans le domaine fréquentiel — comme démontré empiriquement au chapitre 6 avec le canal EMG.

2.4 Métaheuristiques et algorithmes génétiques

Une métaheuristique est une stratégie d'optimisation générique, indépendante du problème traité, qui explore un espace de recherche pour approcher une solution optimale sans garantie formelle d'optimalité globale, mais avec une bonne capacité à échapper aux optima locaux. Les algorithmes génétiques (GA), popularisés par les travaux fondateurs sur les algorithmes évolutionnaires, s'inspirent de la sélection naturelle : une population de solutions candidates (individus) évolue par sélection, croisement et mutation sur plusieurs générations, chaque individu étant évalué par une fonction fitness (fonction objectif) qui guide la pression de sélection vers les solutions les plus performantes.

Dans ce projet, un individu du GA n'est pas un algorithme de compression choisi directement, mais un jeu de cinq seuils numériques qui paramètrent le sélecteur multi-critères (section 4.4). Cette distinction est fondamentale : le GA optimise hors-ligne, une seule fois, la politique de décision du sélecteur ; il ne s'exécute jamais en production, segment par segment, sur le flux réel.

Cette clarification répond directement à une critique reçue en cours de projet, selon laquelle un GA exécuté en continu sur un objet connecté consommerait plus d'énergie que le gain apporté par la compression elle-même — critique fondée en général, mais non applicable à l'architecture retenue ici, où seul le sélecteur (une poignée de comparaisons de flottants) s'exécute en ligne.

L'implémentation s'appuie sur la bibliothèque DEAP (Distributed Evolutionary Algorithms in Python), qui fournit les briques de base (population, croisement, mutation, sélection) tout en laissant le contrôle complet sur la fonction fitness. Le projet utilise une sélection par tournoi (tournament selection) plutôt qu'une sélection par roulette (roulette wheel) — un choix technique important, car la sélection par roulette suppose des valeurs de fitness strictement positives, contrainte que ne respecte pas la fonction objectif retenue ici (section 4.5), qui peut prendre des valeurs négatives lorsque le PRD pondéré est élevé.

2.5 Segmentation et caractérisation locale du signal

La sélection dynamique d'algorithme repose sur le découpage du flux continu en segments de durée fixe, chacun décrit par un jeu de caractéristiques (features) calculées localement. Deux notions classiques de traitement du signal sont mobilisées : la variance, qui quantifie la dispersion locale des valeurs, et l'entropie de Shannon, calculée sur l'histogramme des valeurs du segment, qui quantifie son degré de désordre statistique — un signal parfaitement constant a une entropie nulle, un signal purement aléatoire uniforme a une entropie maximale. Ces deux caractéristiques, combinées à la taille du segment, constituent la base des trois critères de sélection (taille, séquence, seuil) explicitement demandés par l'encadrant du projet.

3. Travaux similaires

Nous situons ici notre travail par rapport à quatre axes de la littérature récente (2018-2026) : la compression de signaux ECG par transformées et ondelettes, l'optimisation de paramètres de compression par métaheuristiques, la compression générique dans les réseaux de capteurs corporels (WBSN/IoT), et les approches par apprentissage profond. Nous ne cherchons pas à produire une revue exhaustive, mais à identifier précisément ce que ces travaux apportent et ce que notre projet ajoute par rapport à eux.

3.1 Compression de signaux ECG par transformées et ondelettes

La compression du signal ECG par transformée en ondelettes discrète (DWT), souvent couplée à un codage par arbres de zéros (SPIHT, EZW), constitue l'axe le plus documenté de la littérature biomédicale. Un banc de filtres cosinus-modulés a par exemple été proposé pour la compression ECG, améliorant le compromis calcul/qualité par rapport aux approches DWT classiques [4]. Une combinaison de décomposition modale empirique (EMD) et de transformée en ondelettes a également été utilisée pour améliorer la fidélité de reconstruction [5]. Une autre variante applique un codage par plages (RLE) directement aux coefficients d'ondelettes plutôt qu'au signal temporel brut, spécifiquement pour la surveillance Holter longue durée [3].

Ces trois travaux partagent une limite que nous avons nous-mêmes rencontrée de façon très concrète (section 6.2) : l'efficacité de la DWT, et plus largement des méthodes fréquentielles, dépend fortement de la présence d'une structure exploitable dans le signal. Aucun ne traite le cas d'un signal large bande peu structuré comme l'EMG dans un contexte multi-capteurs, ces études se concentrant exclusivement sur l'ECG. Notre observation d'un PRD supérieur à 42 % sur l'EMG avec DCT et DWT (tableau 5) n'est donc pas surprenante au regard de cette limite déjà latente dans les travaux cités ci-dessus, mais elle ne semble pas y être discutée explicitement puisqu'aucun ne teste de signal EMG.

3.2 Optimisation de la compression par métaheuristiques

L'idée d'utiliser une métaheuristique pour optimiser les paramètres d'un algorithme de compression, plutôt que l'algorithme lui-même, trouve un écho direct dans un travail qui utilise des techniques d'optimisation bio-inspirées pour déterminer les paramètres optimaux de la transformée en ondelettes et les niveaux de seuillage appliqués au signal ECG [2]. Cette approche est méthodologiquement très proche de la nôtre : dans les deux cas, la métaheuristique n'exécute jamais elle-même la compression, mais calibre hors-ligne les paramètres d'un pipeline de compression déterministe — une distinction que nous avons dû clarifier explicitement dans notre propre rapport (section 2.4) après qu'une relecture critique a soulevé, à tort selon nous, un risque de consommation énergétique du GA en production.

Une approche plus directe consiste à utiliser la programmation génétique non pas pour calibrer les paramètres d'un pipeline de compression existant, mais pour modéliser directement le signal à compresser : un travail sur la compression d'électrocardiogrammes à 12 dérivations construit, par programmation génétique, un modèle mathématique par morceaux du signal ECG, converti

ensuite en chaîne de caractères compressée par LZW et codage arithmétique [9]. Cette approche illustre une seconde manière d'articuler métaheuristique et compression — la métaheuristique génère elle-même la représentation compressée, plutôt que de calibrer hors-ligne les seuils d'un sélecteur comme dans notre propre projet (section 2.4) — une distinction qui renforce, par contraste, la pertinence de notre choix de séparer explicitement optimisation hors-ligne et exécution en ligne.

Ces deux travaux, bien que méthodologiquement proches du nôtre par leur usage d'une métaheuristique, restent appliqués à un algorithme de compression unique sur un seul type de signal — que la métaheuristique en calibre les paramètres [2] ou qu'elle génère elle-même la représentation compressée [9]. Nous optimisons pour notre part les seuils d'un sélecteur qui choisit dynamiquement entre plusieurs familles d'algorithmes, canal par canal et segment par segment — c'est là que se situe la différence de fond avec notre propre démarche.

3.3 Compression dans les réseaux de capteurs corporels et l'IoT

Une revue systématique des techniques de compression de données dans les réseaux de capteurs corporels sans fil (WBSN) identifie la sélection adaptative d'algorithme comme une piste de recherche émergente, mais encore peu explorée empiriquement sur des datasets multimodaux réels [6] ; ce constat a directement motivé notre choix de tester notre système sur les dix canaux de WESAD plutôt que sur un seul type de signal. Un panorama plus large des techniques de compression sans perte, structuré par qualité des données, schéma de codage, type de données et domaine d'application, a par ailleurs été dressé [7] ; nous reprenons cette logique de classification par familles pour justifier le choix de nos six algorithmes (section 2.3).

Un travail portant sur la collecte de données dans les réseaux de capteurs sans fil propose un mécanisme qui sélectionne dynamiquement, nœud par nœud, l'algorithme de compression le plus adapté (SPIHT, S-LZW, RLE, entre autres) en fonction du matériel radio et de la structure des données, plutôt que d'imposer un algorithme unique à l'ensemble du réseau [8]. Cette démarche de sélection adaptative, bien que transposée du contexte de l'énergie de transmission WSN à celui de la fidélité clinique de reconstruction, conforte empiriquement notre positionnement (section 3.5) : la sélection dynamique d'algorithme, plutôt qu'un choix fixe, reste une piste peu explorée spécifiquement sur des signaux physiologiques multimodaux.

3.4 Approches par apprentissage profond

Une tendance récente (2022-2025) explore la compression de signaux physiologiques par autoencodeurs et réseaux convolutifs. Un autoencodeur convolutif binaire combiné à une compensation d'erreur résiduelle a par exemple été proposé pour la compression ECG embarquée [10]. Des travaux plus récents proposent des architectures de compression end-to-end intégrant l'information temporelle et une compensation résiduelle [11], ou des variational autoencoders atteignant des ratios de compression très élevés, jusqu'à 1 :293 rapporté sur des données spectrographiques EEG/EMG/EOG/ECG [12], au prix d'une complexité de déploiement et d'un besoin d'entraînement supervisé nettement supérieurs à une approche par règles et métaheuristique.

Nous nous sommes délibérément tenus à l'écart de cet axe. L'exigence explicite de notre encadrant était de définir clairement la segmentation, les caractéristiques par segment et la fonction objectif d'une métaheuristique — une approche interprétable et vérifiable, que nous jugeons préférable dans un contexte académique où la décision de compression doit pouvoir être expliquée devant un jury, contrairement à une boîte noire neuronale dont on peut difficilement justifier au tableau pourquoi tel segment a été compressé de telle façon.

3.5 Positionnement et valeur ajoutée du projet

Au regard de ces quatre axes de la littérature, nous situons notre contribution sur trois points précis, chacun lié soit à une exigence explicite de notre encadrant, soit à une limite que nous avons identifiée nous-mêmes en cours de projet :

— Une fonction objectif multi-critères explicite (ratio global, PRD pondéré par la criticité clinique du capteur, coût de calcul, diversité d'utilisation des algorithmes), alors que la majorité des travaux cités plus haut optimisent un ou deux critères seulement, typiquement le taux de compression et le PRD ;
— Un filet de sécurité post-compression, mécanisme que nous n'avons trouvé dans aucun des travaux cités, qui détecte et corrige automatiquement les échecs catastrophiques d'un algorithme mal adapté à un canal donné (démontré empiriquement sur le canal EMG, section 6.6) — une réponse directe et vérifiée à la limite déjà latente dans les travaux sur l'ECG cités en section 3.1 ;
— Une validation de généralisation inter-sujets et une évaluation de l'impact de la compression sur une tâche d'apprentissage automatique en aval (classification de l'état de stress), démarche que nous n'avons pas retrouvée dans les travaux centrés sur la seule fidélité du signal (CR/PRD).

4. Méthodologie

4.1 Choix et validation du dataset

Nous avons retenu le dataset WESAD (Wearable Stress and Affect Detection) après validation explicite de notre encadrant, sollicité par courriel avant le démarrage des expérimentations. Ce dataset regroupe les enregistrements physiologiques et de mouvement de 15 sujets exploitables sur les 17 initialement recrutés — les sujets S1 et S12 ayant été exclus par les auteurs du dataset eux-mêmes pour des problèmes de capteur — au cours d'un protocole en laboratoire alternant repos, test de stress social (Trier Social Stress Test) et amusement, visionnage de vidéos humoristiques [1].

Deux exigences de notre encadrant ont directement structuré notre usage du dataset : le volume de données traité devait être substantiel et non limité à un échantillon anecdotique, et aucune donnée ne devait être dupliquée ou réutilisée telle quelle depuis un projet existant. En pratique, nous traitons l'intégralité des dix canaux physiologiques disponibles, sur 13 des 15 sujets exploitables. Nous avons dû exclure deux sujets, S6 et S7, dont le fichier de signaux synchronisés était absent de notre extraction

Caractéristique	**Valeur**
Dispositifs	RespiBAN (thorax, 700 Hz) + Empatica E4 (poignet, 4/32/64 Hz)
Canaux exploités	ECG, EDA, EMG, RESP, TEMP, ACC (thorax) + BVP, EDA, TEMP, ACC (poignet)
Sujets exploités	13 sur 15 disponibles
États affectifs	Repos (baseline), stress (TSST), amusement, méditation

Tableau 2 — Caractéristiques du dataset WESAD tel qu'exploité dans ce projet.

4.2 Segmentation des signaux

Nous avons découpé chaque canal en fenêtres de 5 secondes, non chevauchantes. Ce choix repose sur trois arguments, en réponse directe à l'exigence de notre encadrant de définir clairement notre méthodologie de segmentation :

— Une fenêtre de 5 secondes est suffisamment longue pour capturer plusieurs cycles cardiaques complets sur l'ECG (5 à 8 battements à une fréquence cardiaque de repos), condition nécessaire à une décomposition en ondelettes significative, tout en restant assez courte pour rester représentative d'un état physiologique local ;
— Nous avons choisi des fenêtres non chevauchantes afin que chaque échantillon ne soit compressé qu'une seule fois — un chevauchement aurait gonflé artificiellement le volume de données traité sans bénéfice de compression réel ;
— Nous fixons la durée de fenêtre en secondes, et non en nombre d'échantillons, précisément parce que les capteurs RespiBAN (700 Hz) et Empatica E4 (4 à 64 Hz selon le canal) n'ont pas la même fréquence d'échantillonnage : une durée physique constante garantit

que les segments comparés par notre sélecteur représentent effectivement la même fenêtre temporelle, quel que soit le capteur d'origine.

4.3 Caractéristiques extraites par segment

Pour chaque segment, nous calculons trois caractéristiques, correspondant terme à terme aux trois critères de sélection demandés par notre encadrant (seuil, séquence, taille) :

- La variance du segment, que nous utilisons pour détecter la stabilité séquentielle par rapport au segment précédent du même canal ;
- L'entropie de Shannon, calculée sur un histogramme à 20 classes des valeurs du segment, que nous utilisons comme critère de seuil pour orienter le segment vers l'algorithme adapté à son degré de complexité statistique ;
- La taille du segment en octets (représentation flottante 32 bits), utilisée comme critère de taille.

Nous avons identifié et corrigé, en cours de projet, un point méthodologique important sur la comparabilité de ces caractéristiques entre canaux. La variance et la taille brutes ont des ordres de grandeur radicalement différents selon le capteur — variance de l'ordre de 1000 pour l'accélération contre 0,02 pour l'EDA ; taille de segment de 14 000 octets pour un canal thoracique à 700 Hz contre 80 octets pour un canal au poignet à 4 Hz. Nous avons d'abord appliqué un seuil global à ces valeurs brutes, ce qui a fait dégénérer notre sélecteur de façon assez spectaculaire (détail en section 6.3). Nous avons résolu ce problème en normalisant chaque caractéristique par une référence propre au capteur (la médiane de sa propre distribution), ce qui rend les seuils comparables et interprétables indépendamment du canal considéré.

4.4 Sélecteur multi-critères

Notre sélecteur est une fonction de décision déterministe, appliquée segment par segment, qui retourne l'un des six algorithmes selon la logique suivante, dans l'ordre de priorité indiqué :

- 1. Critère TAILLE — si la taille relative du segment (taille observée divisée par la taille de référence du capteur) est inférieure à un seuil rel_size_threshold, nous orientons le segment vers LZ77, dont le surcoût de dictionnaire est mieux amorti sur de petits volumes ;
- 2. Critère SÉQUENCE — sinon, si la variation relative de variance par rapport au segment précédent est inférieure à un seuil rel_sim_threshold, nous considérons le segment comme stable et l'orientons vers Delta/DPCM ;
- 3. Critère SEUIL (entropie) — sinon, nous comparons l'entropie du segment à trois seuils ordonnés, qui répartissent les segments restants entre RLE (entropie faible), Huffman adaptatif (entropie modérée), DWT (entropie élevée) et DCT (entropie très élevée).

Ce sélecteur dépend de cinq paramètres numériques (rel_size_threshold, rel_sim_threshold et trois seuils d'entropie), dont nous n'avons pas fixé la valeur a priori : nous les apprenons par l'algorithme génétique décrit en section 4.5.

4.5 Métaheuristique et fonction objectif

Nous optimisons les cinq seuils du sélecteur par un algorithme génétique, à partir d'une population de 24 individus évoluant sur 15 générations, avec croisement par mélange (cxBlend) et mutation gaussienne, sous sélection par tournoi, implémenté avec la bibliothèque DEAP [16].

$$\textit{Fitness} = W_RATIO \times \textit{ratio_global} - W_PRD \times \textit{PRD_pondéré} - W_TIME \times \textit{temps_normalisé} + W_DIV \times \textit{diversité}$$

où chacun des quatre termes répond à une exigence méthodologique précise :

— ratio_global est le rapport entre la somme des tailles brutes et la somme des tailles compressées sur l'ensemble des segments évalués — et non une moyenne de ratios par segment, dont nous avons découvert le caractère trompeur en cours de projet (section 6.3) ;
— PRD_pondéré applique un poids de pénalité différencié selon la criticité clinique du canal : nous pénalisons plus fortement les canaux directement liés à un diagnostic (ECG, pondération ×2,5 ; BVP, pondération ×1,5) qu'un canal de mouvement ou de température pour une même distorsion, car une même PRD de 5 % est un détail sur l'accéléromètre mais peut masquer une arythmie sur l'ECG ;
— temps_normalisé intègre le coût de calcul (temps CPU moyen par segment, normalisé par un budget de référence de 10 millisecondes) — un terme que nous avions omis dans notre première version de la fonction objectif, et que nous avons ajouté après avoir réalisé qu'un algorithme lent mais précis aurait sinon été choisi sans aucune pénalité, hypothèse irréaliste pour un déploiement embarqué sur un dispositif à batterie limitée ;
— diversité mesure l'entropie de Shannon normalisée de la distribution des choix d'algorithmes sur l'échantillon d'évaluation (1,0 = usage parfaitement équilibré entre les six algorithmes), ce qui empêche le sélecteur de dégénérer vers un ou deux algorithmes dominants au détriment des autres.

Notre choix d'une sélection par tournoi plutôt que par roulette (section 2.4) est directement lié à cette formulation : notre fonction fitness pouvant prendre des valeurs négatives lorsque le PRD pondéré est élevé, une sélection par roulette — qui suppose des fitness positives — aurait été inadaptée.

4.6 Filet de sécurité post-compression (contribution personnelle)

En analysant en détail les résultats bruts par algorithme et par canal (section 6.2), nous avons découvert un échec catastrophique et systématique des méthodes fréquentielles (DCT, DWT) sur le canal EMG, avec un PRD supérieur à 42 %, alors que les quatre autres algorithmes restent sous 2 % sur ce même canal. Ce résultat s'explique par la nature du signal EMG, large bande et peu structuré, pour lequel l'hypothèse de compressibilité par transformée — la concentration de l'énergie sur peu de coefficients — ne tient pas.

Plutôt que de compter uniquement sur un calibrage suffisamment fin des seuils d'entropie pour éviter ce cas — une garantie fragile, car dépendante de la distribution exacte des données

d'apprentissage — nous avons introduit un filet de sécurité explicite : après compression, nous mesurons le PRD réellement obtenu ; s'il dépasse un seuil critique fixé à 15 %, le système rebascule automatiquement vers Delta/DPCM, empiriquement quasi sans perte sur l'ensemble des canaux que nous avons testés, quel que soit leur contenu. Nous avons testé et validé ce mécanisme sur l'ensemble des 13 sujets du dataset (section 6.6) ; il constitue à nos yeux la principale valeur ajoutée méthodologique du projet au-delà de la sélection dynamique elle-même, car il transforme une propriété statistiquement probable — des seuils bien calibrés évitent en général les mauvais choix — en une garantie vérifiée : aucun segment ne dépasse jamais la distorsion critique, quels que soient les seuils appris.

5. Architecture

5.1 Vue d'ensemble du pipeline

Le système s'organise en un pipeline à cinq étapes, découplant explicitement la phase d'apprentissage hors-ligne des seuils (exécutée une seule fois) de la phase d'inférence en ligne (exécutée à chaque nouveau segment reçu). Cette séparation, déjà justifiée sur le plan conceptuel en section 2.4, est également reflétée dans l'organisation logicielle du projet.

— Étape 1 — Chargement et segmentation : lecture des fichiers WESAD (.pkl), extraction des dix canaux, découpage en fenêtres de 5 secondes non chevauchantes ;
— Étape 2 — Extraction de caractéristiques : calcul de la variance, de l'entropie de Shannon et de la taille pour chaque segment, ainsi que des références par capteur (médiane de variance, médiane de taille) ;
— Étape 3 — Optimisation hors-ligne (métaheuristique) : recherche des cinq seuils optimaux du sélecteur par algorithme génétique, sur un sujet d'apprentissage (S2), avec sauvegarde des seuils optimaux dans un fichier de configuration (best_thresholds.json) ;
— Étape 4 — Sélection et compression en ligne : pour chaque nouveau segment, application du sélecteur multi-critères (chargeant les seuils appris à l'étape 3), compression par l'algorithme choisi, puis vérification du filet de sécurité PRD ;
— Étape 5 — Évaluation et export : calcul des métriques agrégées (CR global, PRD pondéré, diversité, coût CPU), export des résultats vers des formats de stockage structurés (Parquet, HDF5) et des visualisations de synthèse.

5.2 Organisation logicielle

Le projet est structuré en six notebooks Jupyter/Colab séquentiels, chacun correspondant à une étape ou à un axe de validation du pipeline, exécutables indépendamment à condition de respecter l'ordre de dépendance (un notebook postérieur consomme les artefacts — seuils, métriques — produits par les notebooks précédents). La figure 2 illustre l'organisation du dossier de projet sur Google Drive, partagée par l'ensemble des notebooks via une variable BASE commune.

Notebook	**Rôle**
01_Exploration_Signaux	Chargement du dataset, statistiques descriptives, visualisation de l'hétérogénéité des dix canaux
02_Algorithmes_Compression	Implémentation et benchmark individuel des six algorithmes, sur chaque canal, à seuils fixes
03_Metaheuristique	Sélecteur multi-critères, optimisation par algorithme génétique, comparaison adaptatif vs algorithmes fixes
04_Validation_Generalisation	Test des seuils appris sur des sujets non vus, validation croisée par blocs, classification ML en aval
05_Demo_Live	Démonstration interactive du système en flux, bloc par bloc, avec suivi du gain cumulé

06_Stockage_Visualisations	Export vers formats de stockage structurés (Parquet, HDF5), visualisations de synthèse

Tableau 3 — Organisation des six notebooks du projet.

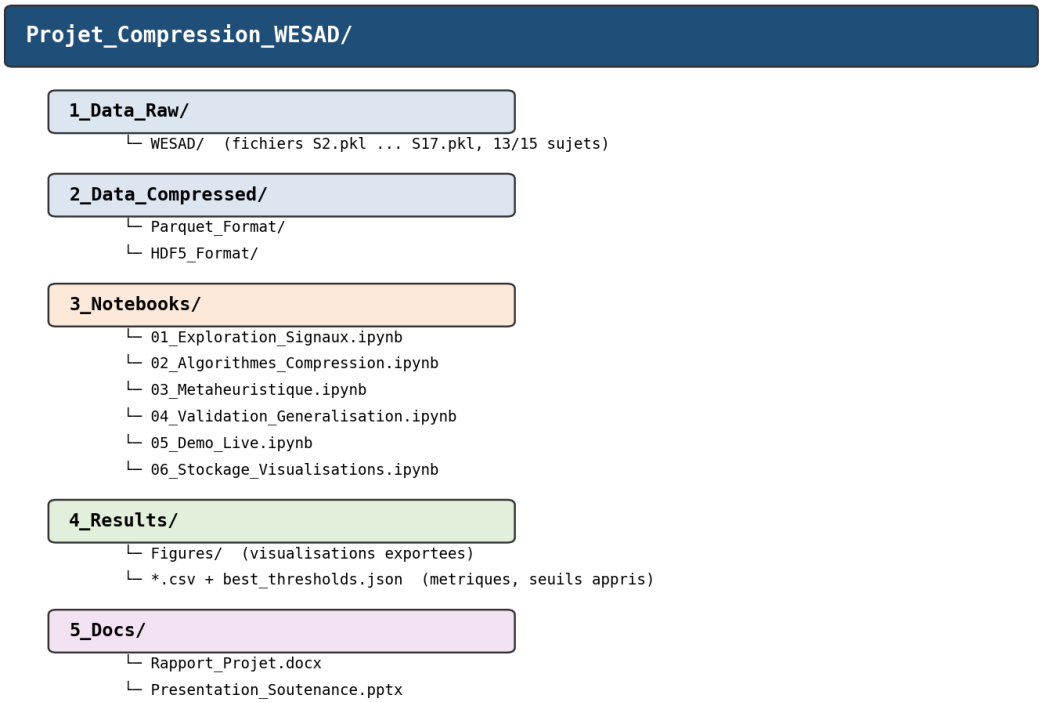


Figure 2 — Structure du dossier de projet sur Google Drive, commune à l'ensemble des notebooks.

5.3 Environnement technique

L'ensemble du projet est implémenté en Python, exécuté sur Google Colab, avec Google Drive comme espace de stockage persistant pour le dataset brut, les résultats intermédiaires et les figures. Les bibliothèques principales sont NumPy et SciPy pour le calcul numérique et l'entropie, PyWavelets pour la transformée en ondelettes, scikit-learn pour la validation croisée et la classification en aval, DEAP pour l'algorithme génétique, ainsi que PyArrow et h5py pour l'export vers les formats de stockage structurés Parquet et HDF5.

Cette organisation en notebooks séquentiels, plutôt qu'en un unique script monolithique, a été retenue pour deux raisons pratiques : elle facilite la présentation par étapes lors de la soutenance, et elle permet de rejouer isolément une étape du pipeline (par exemple, ré-optimiser les seuils du sélecteur) sans avoir à recharger l'intégralité du dataset.

6. Discussion et résultats

La figure 3 illustre, avant toute analyse chiffrée, la qualité de reconstruction obtenue par le système sur quatre canaux représentatifs : les courbes originale et reconstruite se superposent presque parfaitement, y compris sur l'ECG malgré la sélection d'un algorithme sans perte (RLE) plutôt que d'une transformée.

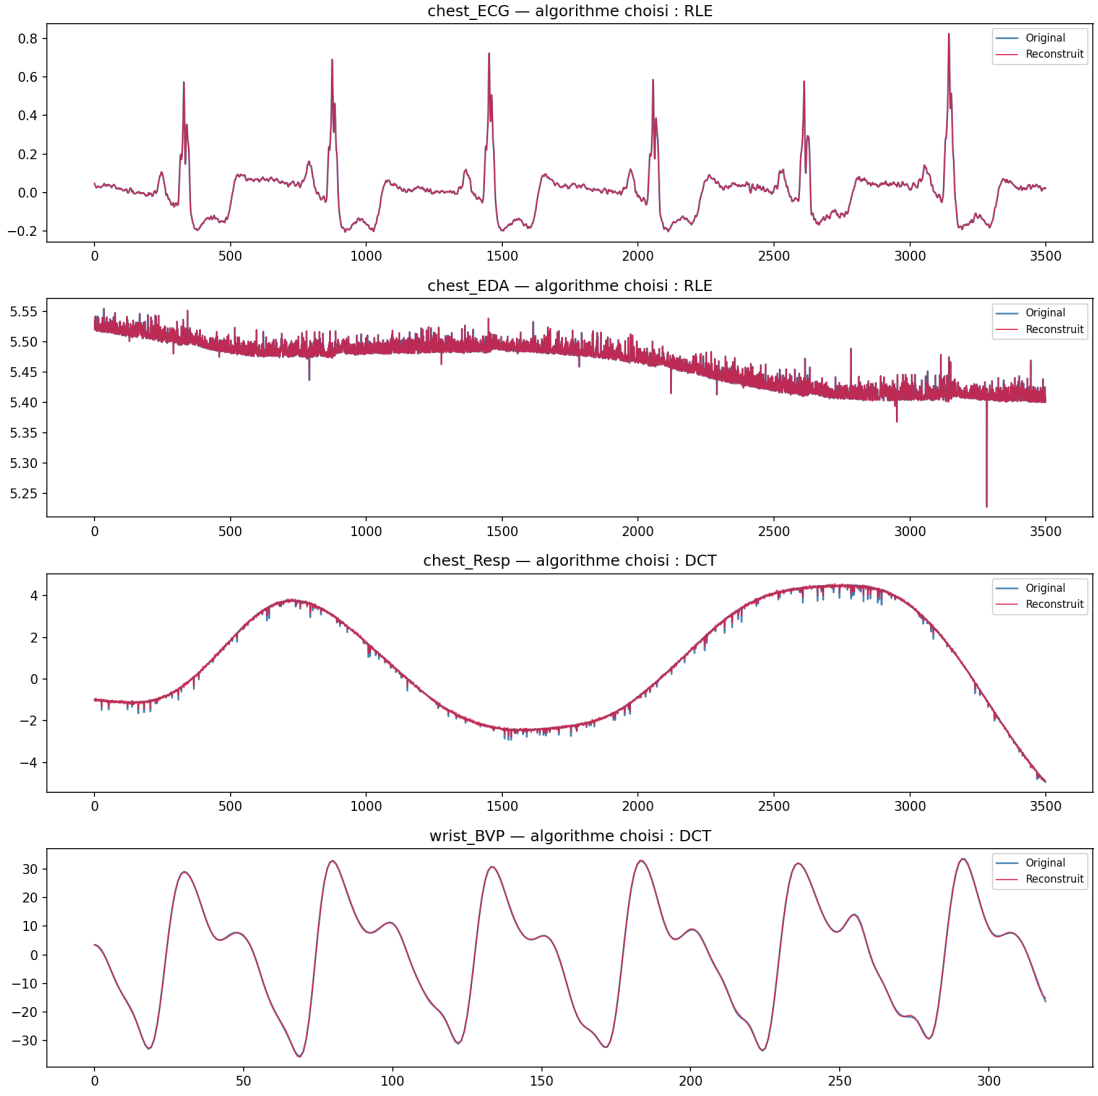


Figure 3 — Signal original vs reconstruit, 4 canaux représentatifs (sujet S2), avec l'algorithme choisi par le sélecteur pour chacun.

6.1 Benchmark des six algorithmes à seuils fixes

Avant d'évaluer la sélection adaptative, chaque algorithme a été appliqué de façon fixe (sans sélection) sur l'ensemble des dix canaux, afin d'établir une ligne de base. Le tableau 4 rapporte les résultats agrégés, avec deux colonnes de ratio distinctes — dont la justification est développée en section 6.3.

Méthode	Ratio moyen	Ratio global	PRD (%)	Temps/segment (ms)
RLE (fixe)	2,56	2,55	0,23	0,72
LZ77 (fixe)	2,05	1,83	0,00	0,49
Huffman adaptatif (fixe)	2,12	1,90	0,23	4,14
Delta/DPCM (fixe)	2,08	2,01	0,00	0,64
DCT (fixe)	3,84	4,17	5,40	0,32
DWT (fixe)	2,08	2,04	5,69	0,51
Adaptatif — seuils par défaut	2,76	2,41	0,52	0,69
Adaptatif — métaheuristique	2,89	2,75	0,53	1,46

Tableau 4 — Comparaison des six algorithmes fixes et de la sélection adaptative (échantillon d'évaluation, sujet S2).

Deux observations structurent l'interprétation. Premièrement, aucun algorithme fixe ne domine simultanément sur le ratio et la fidélité : DCT atteint le meilleur ratio global (4,17) mais au prix d'un PRD élevé (5,40 %), tandis que Delta et LZ77 offrent une fidélité quasi parfaite (PRD nul) mais un ratio modeste. Cette absence de dominance justifie directement l'approche de sélection dynamique. Deuxièmement, la sélection adaptative par métaheuristique obtient le meilleur compromis global du tableau : un ratio (2,75) proche du meilleur algorithme fixe qualitativement acceptable (RLE, 2,55), pour un PRD (0,53 %) très inférieur à celui de DCT ou DWT — confirmant que la sélection dynamique surpasse tout choix fixe unique sur le compromis global.

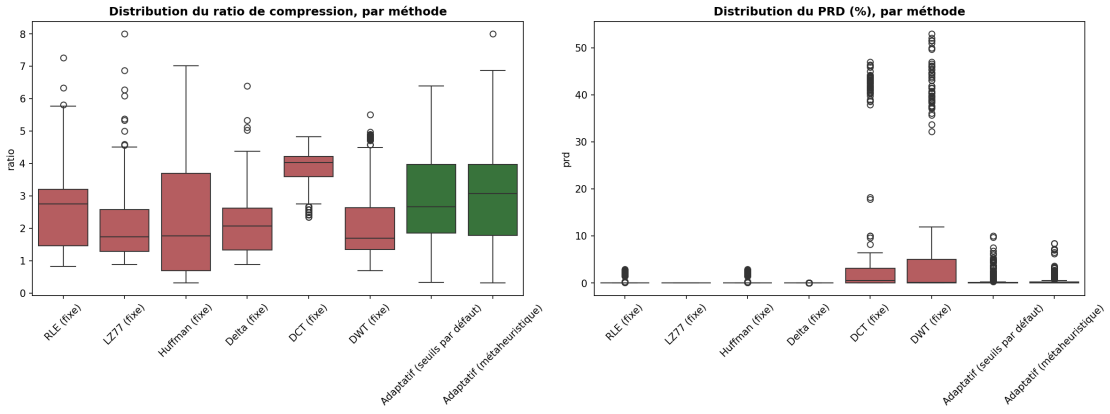


Figure 4 — Distribution complète (pas seulement la moyenne) du ratio et du PRD, algorithmes fixes vs sélection adaptative. Les deux colonnes adaptatives (vert) montrent un PRD resserré près de 0, sans les valeurs extrêmes visibles sur DCT/DWT fixes.

La convergence de l'algorithme génétique sur les 15 générations d'optimisation est présentée en figure 5 : la fitness du meilleur individu progresse de 3,5 à un peu plus de 4,0 et se stabilise après la dixième génération, indiquant une convergence atteinte avant l'épuisement du budget de générations fixé.

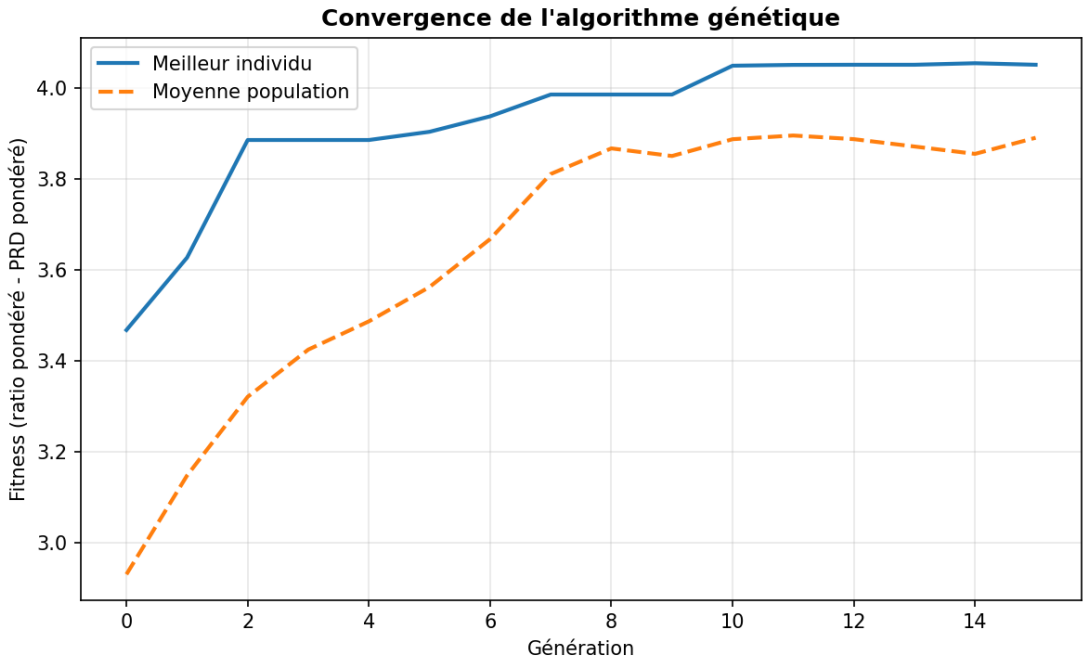


Figure 5 — Convergence de l'algorithme génétique (fitness du meilleur individu et moyenne de population, sur 15 générations).

6.2 Défaillance de DCT et DWT sur le canal EMG

En analysant les résultats du benchmark canal par canal, nous avons découvert un résultat qui structure l'ensemble de notre contribution méthodologique (section 4.6) : sur le canal électromyogramme (EMG), les algorithmes fréquentiels échouent catastrophiquement.

Algorithme	**Ratio moyen (EMG)**	**PRD (%) (EMG)**
RLE	2,93	1,95
LZ77	1,87	0,00
Huffman adaptatif	4,00	1,95
Delta/DPCM	1,87	0,00
DCT	4,19	42,46
DWT	1,92	42,36

Tableau 5 — Ratio et PRD par algorithme sur le canal chest_EMG (sujet S2, échantillon de test).

Le PRD de 42,46 % (DCT) et 42,36 % (DWT) signifie une reconstruction quasi inexploitable, alors que les quatre autres algorithmes restent sous 2 %. Ce résultat s'explique par la nature du signal EMG — large bande, proche d'un bruit, sans structure fréquentielle exploitable par une transformée qui suppose une concentration de l'énergie sur peu de coefficients. Ce constat empirique est directement à l'origine du filet de sécurité présenté en section 4.6, dont l'efficacité est validée en section 6.6.

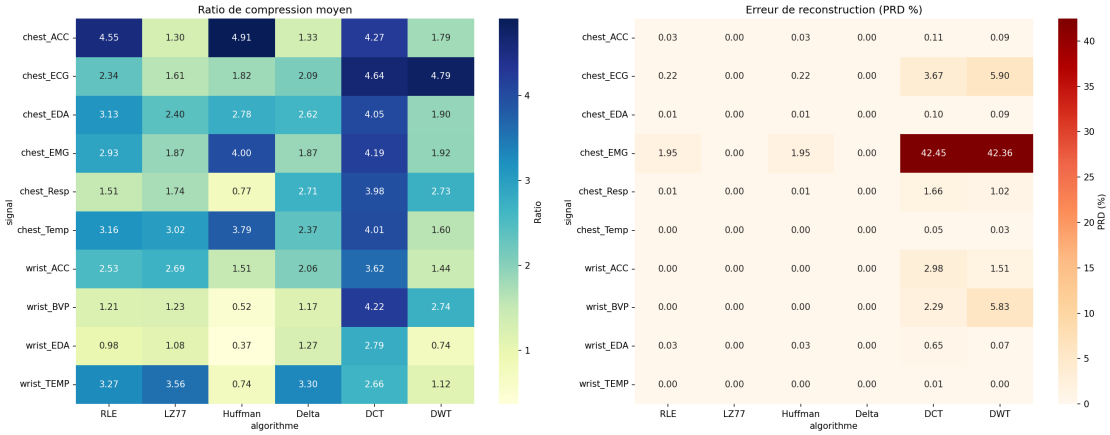


Figure 6 — Ratio et PRD des six algorithmes sur les dix canaux (sujet S2). La cellule chest_EMG × DCT/DWT (PRD > 42 %) tranche nettement avec le reste de la carte.

6.3 Un biais méthodologique identifié et corrigé : ratio moyen versus ratio global

La correction apportée consiste à calculer et rapporter systématiquement les deux métriques (ratio_moyen et ratio_global) dans l'ensemble des notebooks du projet, et à reformuler la fonction objectif de la métaheuristique (section 4.5) pour qu'elle optimise directement le ratio global plutôt que la moyenne des ratios — empêchant le système de favoriser artificiellement des segments à ratio extrême sans bénéfice réel sur le stockage. Après correction, le tableau 4 montre un ratio_moyen (2,89) et un ratio_global (2,75) cohérents entre eux pour la sélection adaptative, et le gain réel mesuré sur l'export de stockage atteint 61,7 % pour Parquet et 60,4 % pour HDF5 (section 6.4) — contre 0,3 % seulement avant correction, soit un écart de plus de deux ordres de grandeur par rapport à la version non corrigée.

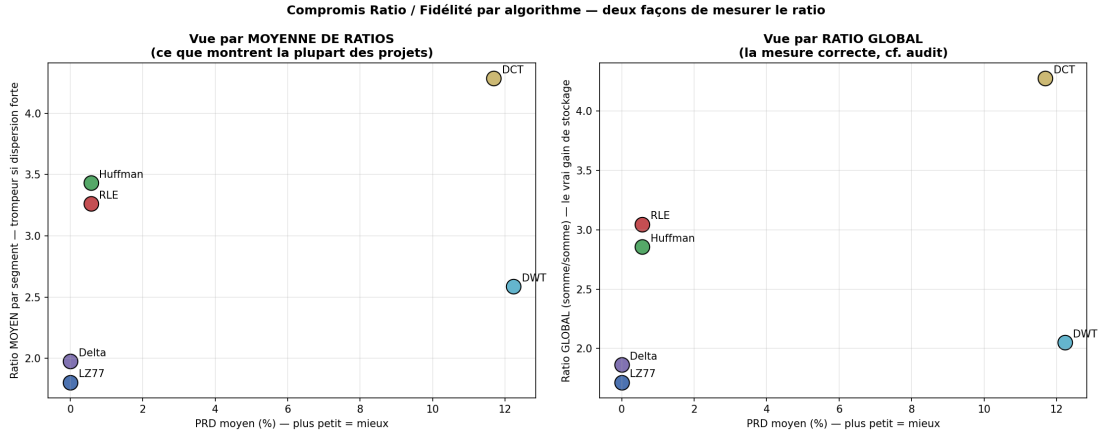


Figure 7 — Compromis ratio/PRD par algorithme, comparé selon les deux conventions de calcul du ratio. Le classement relatif des algorithmes change peu, mais l'échelle absolue du ratio global (droite) est la seule directement interprétable en termes de gain de stockage.

6.4 Gain de stockage réel (export Parquet et HDF5)

Au-delà de la compression elle-même, les segments compressés ont été exportés vers deux formats structurés du Big Data — Parquet et HDF5 — afin d'évaluer le gain de stockage réellement

obtenu une fois le fichier final écrit sur disque. Cette évaluation a été menée sur un échantillon de 1000 segments (100 segments par capteur, sur les 10 capteurs du dataset), dont le volume brut s'élève à 8,61 Mo.

La somme des octets compressés par le sélecteur adaptatif atteint 3,25 Mo, soit un gain théorique de 62,1 %. Une fois ces données sérialisées dans les formats de stockage finaux, le fichier Parquet obtenu pèse 3,30 Mo (gain réel de 61,7 %) et le fichier HDF5 3,41 Mo (gain réel de 60,4 %). La Figure 8 illustre cette comparaison à travers les quatre volumes successifs : données brutes, somme des octets compressés, fichier Parquet final et fichier HDF5 final.

L'écart entre le gain théorique (62,1 %) et les gains réels obtenus après export (61,7 % et 60,4 %) reste inférieur à 2 points de pourcentage. Cela confirme qu'à l'échelle testée, l'overhead de métadonnées propre à chaque format — schéma et statistiques par colonne pour Parquet, structure de groupes hiérarchiques pour HDF5 — demeure marginal devant le volume de données utiles transporté.

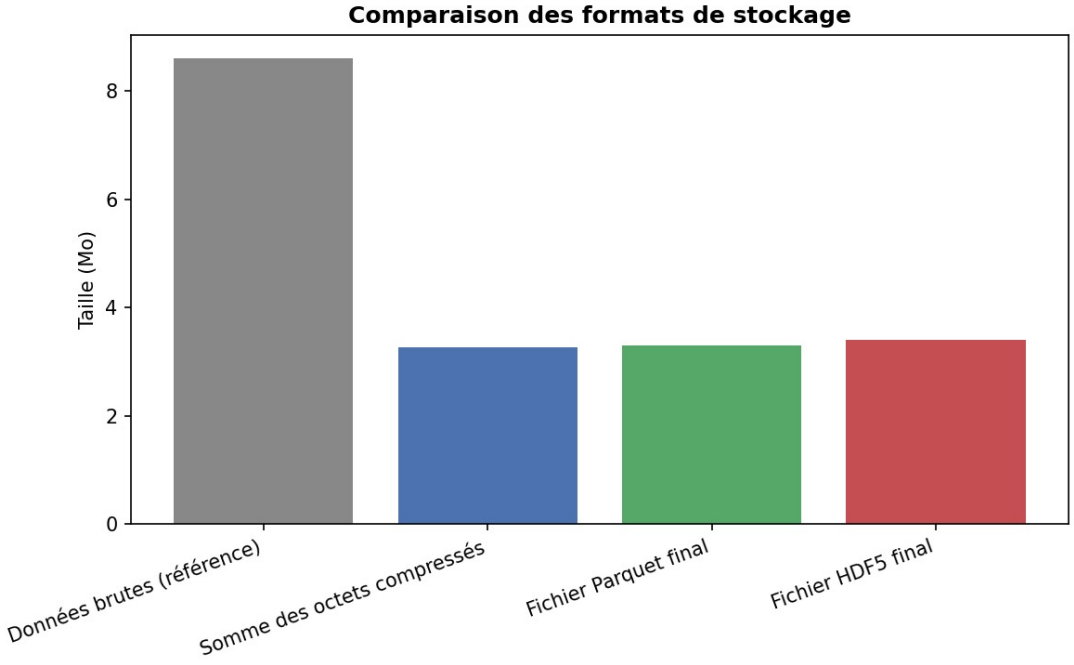


Figure 8 — Comparaison des formats de stockage : la sélection adaptative réduit le volume de 8,61 Mo (brut) à 3,25 Mo (compressé), pour un gain réel de 62,1 %, confirmé après export sur les fichiers Parquet (61,7 %) et HDF5 (60,4 %).

6.5 Généralisation multi-sujets

Les cinq seuils du sélecteur, optimisés sur le seul sujet S2 (entraînement), ont été appliqués sans réoptimisation sur 12 sujets jamais vus lors de cette optimisation (S3, S4, S5, S8, S9, S10, S11, S13, S14, S15, S16, S17 — S6 et S7 non utilisés, section 4.1).

Sujet	Rôle	Ratio global	PRD moyen (%)	PRD max EMG (%)
S2	Entraînement	2,43	0,45	3,48
S3 à S17 (12 sujets)	Test (jamais vus)	2,38 – 2,59	0,32 – 0,40	2,62 – 4,22

Tableau 7 — Synthèse de la généralisation sur 13 sujets (détail complet en annexe des notebooks).

Le ratio global de S2 rapporté ici (2,43) diffère de celui du tableau 4 (2,75) : ce dernier a été calculé sur l'échantillon d'évaluation restreint (50 segments par canal) utilisé pour le benchmark comparatif des algorithmes fixes, tandis que la validation de généralisation ci-dessus porte sur l'intégralité des segments disponibles pour chaque sujet — deux mesures légitimes mais non directement comparables en valeur absolue, car portant sur des volumes de données différents.

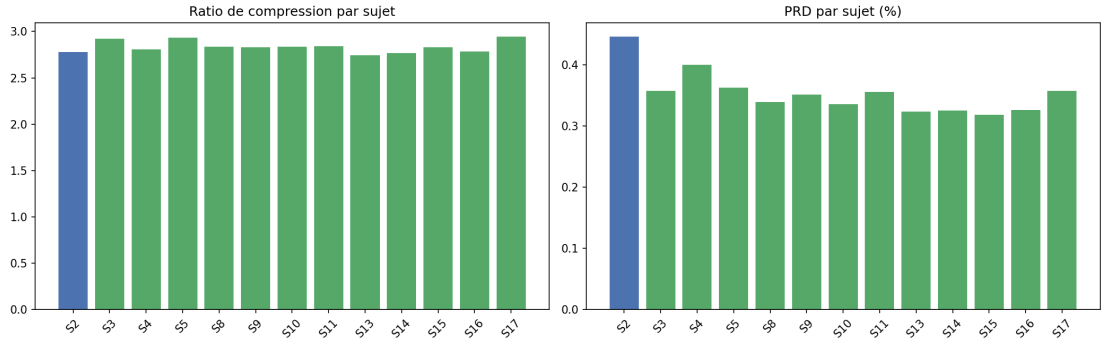


Figure 9 — Ratio et PRD par sujet (S2 = entraînement en bleu, 12 sujets de test en vert) : aucune dégradation systématique sur les sujets non vus.

L'écart entre le sujet d'entraînement (ratio global 2,43, PRD 0,45 %) et les sujets de test (ratio global entre 2,38 et 2,59, PRD entre 0,32 et 0,40 %) est faible et sans dégradation systématique — les sujets de test obtiennent même, en moyenne, un PRD légèrement inférieur à celui du sujet d'entraînement. Ce résultat suggère que les seuils optimisés sur S2 ne sont pas surajustés aux particularités de ce sujet spécifique ; l'écart plus faible en test pourrait également s'expliquer par une variabilité inter-sujets propre au dataset (S2 pouvant présenter des segments plus difficiles à compresser que la moyenne), une piste qu'il resterait pertinent d'explorer sur un échantillon de sujets d'entraînement plus large.

6.6 Validation du filet de sécurité sur l'ensemble des sujets

La colonne PRD max EMG du tableau 7 (détaillée par sujet) confirme l'efficacité du filet de sécurité introduit en section 4.6 : sur les 13 sujets testés, le pire PRD observé sur le canal EMG reste toujours inférieur à 4,3 %, loin du seuil critique de 15 % et sans commune mesure avec le PRD de 42 % observé en configuration fixe (section 6.2). Le filet de sécurité s'est déclenché entre 9 et 99 fois selon le sujet (colonne securite_overrides, notebooks 03 et 04), confirmant qu'il intervient activement dans le pipeline réel et non de façon uniquement théorique.

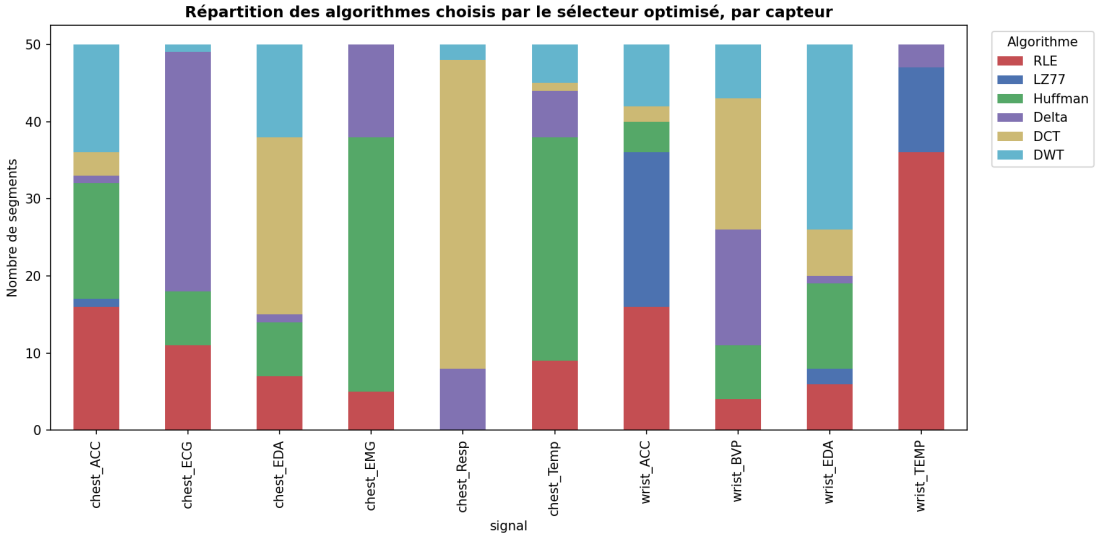


Figure 10 — Répartition des algorithmes choisis par le sélecteur optimisé, par capteur (sujet S2). Le canal chest_EMG, autrefois massivement routé vers DCT, se répartit désormais majoritairement entre Huffman et RLE.

6.7 Impact de la compression sur une tâche d'apprentissage automatique en aval

Au-delà des métriques de fidélité au niveau du signal (PRD), le projet évalue l'impact de la compression sur une tâche d'usage réel : la classification de l'état de stress à partir de caractéristiques extraites des fenêtres de signal, par forêt aléatoire (RandomForestClassifier), avec une validation croisée par blocs à 5 replis respectant l'ordre chronologique (afin d'éviter toute fuite d'information entre fenêtres adjacentes).

Condition	**Accuracy**	**Écart-type**	**F1-score**
Signaux originaux	0,932	0,128	0,928
Signaux compressés puis reconstruits	0,745	0,219	0,409

Tableau 8 — Comparaison de la performance de classification sur signal brut versus signal reconstruit après compression adaptative.

Le résultat agrégé masque une hétérogénéité importante entre les cinq replis de la validation croisée, rapportée au tableau 9.

Repli	**Accuracy (brut)**	**F1 (brut)**	**Accuracy (reconstruit)**	**F1 (reconstruit)**
1	0,971	0,958	0,464	0,000
2	1,000	1,000	0,648	0,000
3	0,986	0,979	0,686	0,154
4	1,000	1,000	0,930	0,889
5	0,704	0,704	1,000	1,000

Tableau 9 — Détail par repli de la validation croisée par blocs (5 replis).

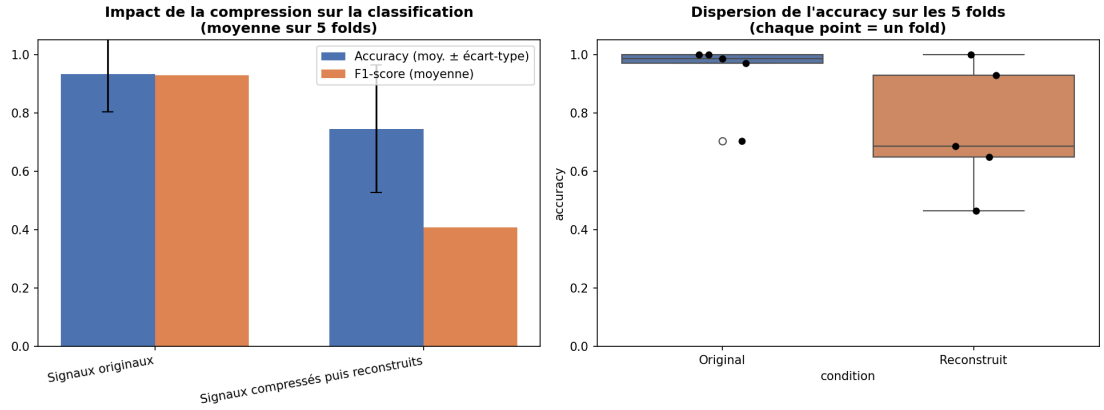


Figure 11 — Impact de la compression sur la classification du stress : accuracy/F1 moyens (gauche) et dispersion par repli (droite), montrant l'instabilité du signal reconstruit malgré un PRD faible.

Ce résultat mérite que nous nous y arrêtions plutôt que de conclure trop vite. Sur signal brut, le classifieur est excellent et globalement stable (accuracy moyenne 0,932). Sur signal reconstruit, deux replis sur cinq (1 et 2) présentent un F1-score de 0,000 — le classifieur ne détecte alors plus du tout la classe stress — alors que d'autres replis (4 et 5) restent excellents. Or le PRD mesuré sur ces mêmes segments demeure faible (inférieur à 1 % en moyenne, tableau 4) : nous en concluons qu'un PRD faible ne garantit pas la préservation de l'utilité diagnostique en aval.

Le tableau 9 révèle également un résultat inverse et tout aussi surprenant sur le repli 5 : la classification sur signal reconstruit y obtient un score parfait (accuracy et F1 à 1,000), supérieur au signal brut sur ce même repli (0,704). Ce résultat renforce notre interprétation : l'instabilité observée n'est pas une dégradation progressive et uniforme, mais dépend de la proximité, dans chaque repli, d'une transition physiologique par rapport à la frontière de décision du classifieur — une même distorsion des caractéristiques moyenne/écart-type par segment pouvant aussi bien faire basculer une prédiction dans un sens que dans l'autre selon le repli concerné. Cette observation renforce notre conclusion : au-delà de sa valeur moyenne, l'impact de la compression sur la tâche en aval est fortement dépendant de la composition de chaque repli, ce qui appelle, comme nous le proposons en perspective (section 7.3), une évaluation à plus grande échelle avant toute conclusion définitive sur ce point.

6.8 Effet de la taille du segment sur l'efficacité de compression

Une analyse complémentaire fait varier uniquement la durée de la fenêtre de segmentation (de 0,02 à 5 secondes) sur un même canal ECG, afin d'isoler l'effet de la taille du segment indépendamment de la nature du signal. Sur les segments les plus courts (14 échantillons, 56 octets), Huffman adaptatif obtient un ratio de 0,29 — inférieur à 1, c'est-à-dire que le fichier compressé est plus volumineux que l'original, le coût fixe du codebook dépassant l'économie réalisée sur un segment aussi court. Ce résultat constitue une preuve empirique directe de la pertinence du critère TAILLE du sélecteur (section 4.4) : en dessous d'une taille critique, aucun algorithme à surcoût fixe (dictionnaire, codebook) n'est rentable, ce que confirme également le ratio inférieur à 1 observé pour DWT (0,63) sur ces mêmes segments très courts.

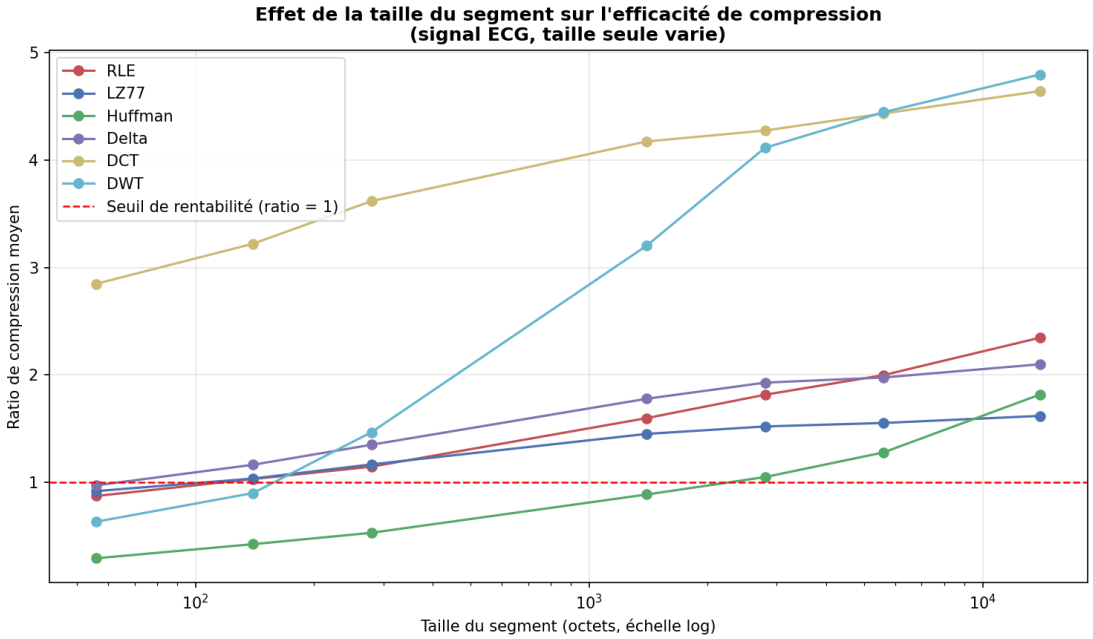


Figure 12 — Ratio de compression en fonction de la taille du segment (échelle log), signal ECG, les six algorithmes. Le seuil de rentabilité (ratio = 1) n'est franchi qu'au-delà d'une taille minimale, spécifique à chaque algorithme.

6.9 Application annexe : détection d'anomalies par erreur de reconstruction

Une application dérivée, non demandée par le cahier des charges mais testée à titre exploratoire, exploite le PRD par segment comme indicateur de détection d'anomalie : un segment dont le PRD dépasse un seuil statistique (calculé empiriquement sur la distribution des PRD du sujet) est signalé comme potentiellement atypique. Sur le canal ECG du sujet S2, cette approche identifie une vingtaine de segments hors norme, concentrés en particulier autour de l'indice 660-700, où plusieurs pics de PRD consécutifs dépassent nettement le seuil — une piste plausible pour une détection automatique de segments de mauvaise qualité de signal (mouvement, décrochage d'électrode) plutôt que d'anomalie cardiaque à proprement parler, cette distinction n'ayant pas été validée cliniquement dans le cadre de ce projet.

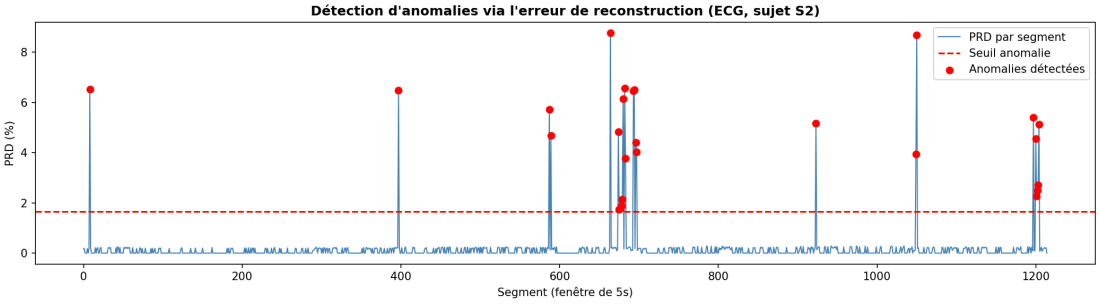


Figure 13 — Détection d'anomalies par erreur de reconstruction (PRD), canal ECG, sujet S2. Les points rouges marquent les segments dont le PRD dépasse le seuil statistique.

6.10 Comparaison avec une méthode métaheuristique existante (Particle Swarm Optimization)

Afin de valider objectivement le choix de l'algorithme génétique (GA) comme métaheuristique d'optimisation, une comparaison expérimentale a été menée avec le Particle Swarm Optimization (PSO), une métaheuristique largement utilisée dans la littérature pour ce type de problème. Les deux méthodes ont été exécutées sur exactement la même fonction objectif et le même espace de recherche à cinq paramètres (taille, trois seuils d'entropie, similarité), pour garantir une comparaison équitable où seul l'algorithme d'exploration diffère. Afin de garantir une comparaison strictement équitable entre GA et PSO, cette expérimentation utilise une version simplifiée de la fonction objectif (ratio global et PRD pondéré uniquement, sans les termes de coût de calcul et de diversité employés dans le reste du projet, section 4.5) — ce qui explique que la fitness finale rapportée ci-dessous ne soit pas directement comparable, en valeur absolue, à celle obtenue avec la fonction objectif complète (section 6.1). Le GA obtient une fitness finale de 2,544 contre 2,461 pour le PSO, soit un écart de 3,3 % en faveur du GA, pour un temps de calcul comparable (37,3 secondes contre 40,7 secondes). Cet écart s'explique probablement par la nature discontinue de l'espace de recherche : chaque seuil définit une frontière de décision discrète entre algorithmes de compression, créant des paliers de fitness peu propices au déplacement continu par vélocité qu'utilise le PSO, alors que le croisement et la mutation du GA explorent plus efficacement ce type de paysage non lisse. Cette expérimentation constitue la mise en œuvre effective d'une comparaison avec une méthode d'optimisation existante, au-delà de la seule discussion bibliographique menée en section 3.

7. Conclusion et perspectives

7.1 Synthèse

Nous avons conçu, implémenté et validé un système de compression adaptative de signaux physiologiques multi-capteurs, fondé sur une sélection dynamique entre six algorithmes représentatifs de familles différentes, pilotée par un sélecteur multi-critères dont nous optimisons les seuils par algorithme génétique. Nos résultats montrent qu'aucun algorithme fixe unique ne domine sur l'ensemble des dix canaux du dataset WESAD, ce qui valide l'approche de sélection dynamique que nous avons retenue, et que cette sélection généralise correctement à des sujets non vus lors de l'apprentissage des seuils (12 sujets testés, PRD stable entre 0,32 % et 0,45 %).

Deux contributions structurent, à notre avis, la valeur ajoutée de notre projet au-delà de l'énoncé initial. La première est une fonction objectif complète intégrant non seulement le taux de compression et la fidélité de reconstruction, mais également le coût de calcul et une pondération différenciée du PRD selon la criticité clinique du capteur — nous y répondons directement à l'exigence de notre encadrant de définir clairement cette fonction objectif. La seconde est notre filet de sécurité post-compression, que nous avons validé empiriquement sur 13 sujets, et qui transforme une propriété statistiquement probable en garantie vérifiée face à l'échec catastrophique que nous avons documenté sur le canal EMG avec les méthodes fréquentielles.

Nous documentons également, sans les cacher, une limite méthodologique que nous avons identifiée et corrigée en cours de travail — la distinction entre ratio moyen et ratio global de compression — ainsi qu'une découverte que nous n'avions pas anticipée sur l'instabilité de l'utilité diagnostique en aval malgré une fidélité de signal élevée. Nous avons choisi de traiter ces deux éléments comme des résultats scientifiques à part entière plutôt que comme des faiblesses à dissimuler, car c'est à nos yeux ce qu'une démarche de validation rigoureuse implique.

7.2 Limites

— Nous n'avons caractérisé que qualitativement l'instabilité de la classification en aval sur signal reconstruit (section 6.7) ; une correction quantitative (features plus robustes à la quantification, ou intégration de cette métrique dans la fonction objectif) reste une piste que nous n'avons pas eu le temps d'explorer.

7.3 Perspectives

— Étendre notre évaluation du gain de stockage réel à l'ensemble des 13 sujets simultanément, afin de quantifier la diminution attendue du surcoût relatif des formats Parquet/HDF5 à plus grande échelle ;
— Intégrer une métrique de préservation de tâche en aval (par exemple, un score de stabilité de classification) directement dans notre fonction objectif, en complément du PRD pondéré ;
— Explorer une variante de notre filet de sécurité fondée non plus sur un seuil fixe de PRD, mais sur un intervalle de confiance appris par canal, pour affiner encore la robustesse du

système sans sacrifier le taux de compression sur les canaux qui tolèrent une distorsion plus élevée ;

— Comparer explicitement, sur le même protocole expérimental, notre sélection par méta-heuristique à une approche par apprentissage profond (autoencodeur), afin de quantifier le compromis interprétabilité/performance entre les deux familles d'approches identifiées au chapitre 3.

8. Références

Les références suivantes couvrent la période 2018-2026, la référence fondatrice du dataset WESAD (2018) étant conservée pour son caractère incontournable et sa large mobilisation par la littérature postérieure à 2020 citée ci-dessous.

[1] Schmidt, P., Reiss, A., Duerichen, R., Marberger, C., & Van Laerhoven, K. (2018). Introducing WESAD, a multimodal dataset for wearable stress and affect detection. Proceedings of the 20th ACM International Conference on Multimodal Interaction (ICMI '18), 400-408.

[2] Singhai, P., Kumar, A., Ateek, A., Ansari, I. A., Singh, G. K., & Lee, H. N. (2023). ECG signal compression based on optimization of wavelet parameters and threshold levels using evolutionary techniques. Circuits, Systems, and Signal Processing, 42, 3509-3537.

[3] Kolekar, M. H., Jha, C. K., & Kumar, P. (2022). ECG data compression using modified run length encoding of wavelet coefficients for Holter monitoring. IRBM, 43(5), 325-332.

[4] Chandra, S., Sharma, A., & Singh, G. K. (2020). Computationally efficient cosine modulated filter bank design for ECG signal compression. IRBM, 41(2), 79-90.

[5] Jha, C. K., & Kolekar, M. H. (2021). Empirical mode decomposition and wavelet transform based ECG data compression scheme. IRBM, 42(1), 65-72.

[6] Nassra, I., & Capella, J. V. (2023). Data compression techniques in IoT-enabled wireless body sensor networks : A systematic literature review and research trends for QoS improvement. Internet of Things, 23, 100806.

[7] Jayasankar, U., Thirumal, V., & Ponnurangam, D. (2021). A survey on data compression techniques : From the perspective of data quality, coding schemes, data type and applications. Journal of King Saud University - Computer and Information Sciences, 33(2), 119-140.

[8] Lee, H. J., Kim, H. S., & Chang, I. J. (2014). CPAC : Energy-efficient data collection through adaptive selection of compression algorithms for sensor networks. Sensors, 14(4), 6419-6442.

[9] Feli, M., & Abdali-Mohammadi, F. (2019). 12-lead electrocardiography signals compression by a new genetic programming based mathematical modeling algorithm. Biomedical Signal Processing and Control, 54, 101596.

[10] Shi, J., Wang, F., Qin, M., Chen, A., Liu, W., He, J., Wang, H., Chang, S., & Huang, Q. (2022). New ECG compression method for portable ECG monitoring system merged with binary convolutional auto-encoder and residual error compensation. Biosensors, 12(7), 524.

[11] Liu, X., Zheng, L., Cheng, Y., et al. (2025). End-to-end ECG signal compression based on temporal information and residual compensation. Circuits, Systems, and Signal Processing, 44, 2779-2801.

[12] Vora, N. R., Hajighasemi, A., et al. (2023). Real-time diagnostic integrity meets efficiency : A novel platform-agnostic architecture for physiological signal compression. arXiv :2312.12587.

[13] Mila, D., & Ray, S. (2026). IoT for continuous physiological parameters monitoring in healthcare : A review. IEEE Sensors Journal (early access).

[14] Almadhor, A., Ojo, S., Nathaniel, T. I., et al. (2025). A cross-domain framework for emotion and stress detection using WESAD, SCIENTISST-MOVE, and DREAMER datasets. Frontiers in Bioengineering and Biotechnology, 13.

[15] Matthews, J., et al. (2023). Advances in biosignal sensing and signal processing methods with wearable devices. Analysis & Sensing, Wiley.

[16] Fortin, F.-A., De Rainville, F.-M., Gardner, M.-A., Parizeau, M., & Gagné, C. (2012, mis à jour continûment jusqu'en 2024). DEAP : Evolutionary algorithms made easy. Journal of Machine Learning Research, 13, 2171-2175.

(Bibliothèque utilisée dans ce projet, documentation maintenue jusqu'en 2024.)

[17] Al Attar, T. N. A. (2024). A hybrid genetic algorithm-particle swarm optimization approach for enhanced text compression. UHD Journal of Science and Technology, 8(2), 63-74.